

Aprendizaje No Supervisado

Métricas de Distancia en Machine Learning

Jessica Melani Romero Lora
Dr. Marcos Yamir Gomez

1. Introducción

Una **métrica de distancia** $d(x, y)$ cuantifica la disimilitud entre dos puntos en un espacio de características. Para ser formalmente una métrica, debe satisfacer cuatro axiomas: (1) no negatividad, (2) identidad de indiscernibles, (3) simetría y (4) desigualdad triangular. La selección adecuada de la métrica determina la geometría del espacio de búsqueda y, por tanto, el comportamiento de algoritmos como k-NN, k-means, SVM y sistemas de recuperación de información. El presente documento analiza cinco métricas fundamentales: Euclidiana, Manhattan, Coseno, Mahalanobis y Jaccard.

2. Cuadro Comparativo

Eje de análisis	Euclidiana	Manhattan	Coseno Mahalanobis	Jaccard
Fórmula	$\sqrt{\sum (x_i - y_i)^2}$	$\sum x_i - y_i $	$\frac{(x \cdot y)}{(\ x\ \cdot \ y\)} \sqrt{(x - y)^T S^{-1} (x - y)}$	$\frac{ A \cap B }{ A \cup B }$
Tipo de dato	Numérico continuo	Numérico continuo / ordinal	Vectores densos (texto, embeddings)	Conjuntos binarios / categórico
Sensibilidad a escala	Alta requiere normalizar	Alta requiere normalizar	Nula invariante a magnitud	Nula basada en intersección
Maldición de dimensionalidad	Severa — distancias convergen	Moderada — más estable que L2	Moderada Baja si S está bien estimada	Baja — opera en espacio discreto

Complejidad computacional	O(d)	O(d)	O(d) O(d^2) — cálculo de S^-1	O(A + B)
----------------------------------	------	------	-------------------------------------	------------

Caso de uso ideal	Imágenes, señales, clustering geométrico	Datos con outliers, Manhattan plots	NLP, recomendación, embeddings, Detección de anomalías multivariadas	Genómica, NLP, recuperación de docs binarios
--------------------------	--	-------------------------------------	--	--

Eje de análisis	Euclidiana	Manhattan	Coseno Mahalanobis	Jaccard
Algoritmos típicos	k-NN, k-means, PCA	LASSO, k-NN robusto, DBSCAN	TF-IDF, BERT, sistemas de rec., Mahal. distance test, one-class SVM	MinHash, LSH, clustering de texto
Limitaciones clave	Sensible a outliers y escala	Ignora correlaciones entre ejes	Ignora la magnitud absoluta, Requiere $n \gg d$ para estimar S	Solo para datos binarios / conjuntos

3. Análisis Individual de Métricas

3.1 Distancia Euclidiana (L²)

$$d(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \dots + (x_n - y_n)^2}$$

Corresponde a la longitud del segmento recto entre dos puntos en el espacio euclídeo. Es la métrica por defecto en k-means (minimiza inercia intra-cluster) y k-NN. **Su principal limitación es la sensibilidad a outliers y la maldición de la dimensionalidad: en dimensión alta, la razón entre la distancia máxima y mínima tiende a 1, perdiendo poder discriminativo. Requiere estandarización previa (z-score o min-max)** cuando las variables tienen escalas heterogéneas.

Aplicaciones diversas en segmentación de imágenes médicas por intensidad de píxel. Cada imagen se representa como un vector de píxeles normalizados; k-means con distancia euclidiana agrupa regiones de tejido homogéneo.

Aplicado en diagnóstico asistido (radiología, dermatología computacional, investigación dermatológica, biomedicina).

3.2 Distancia Manhattan (L^1)

$$d(x, y) = |x_1 - y_1| + |x_2 - y_2| + \dots + |x_n - y_n|$$

Suma de diferencias absolutas coordenada a coordenada. Geométricamente equivale a desplazarse en cuadrícula (calles de Manhattan). Es más robusta a outliers que L^2 porque no eleva las diferencias al cuadrado. En alta dimensión, su concentración de distancias es menos severa que L^2 . Se utiliza como término de regularización en LASSO (L^1), induciendo dispersidad en los coeficientes.

Comúnmente utilizado en detección de fraude y de fraude en transacciones financieras. Los vectores de comportamiento (monto, frecuencia, hora, ubicación) tienen distribuciones muy sesgadas; Manhattan reduce el peso de valores extremos legítimos y permite identificar patrones anómalos con DBSCAN o k-NN.

3.3 Similitud / Distancia Coseno

$$\text{sim}(x, y) = (x \cdot y) / (||x|| \cdot ||y||) \quad \text{dist}(x, y) = 1 - \text{sim}(x, y)$$

Mide el ángulo entre dos vectores, ignorando su magnitud. Dos documentos con el mismo vocabulario proporcional obtienen similitud = 1 independientemente de su longitud. Es la métrica estándar en recuperación de información y NLP: representaciones TF-IDF, word embeddings (Word2Vec, GloVe) y sentence embeddings (BERT) se comparan por coseno. **No satisface la desigualdad triangular** en su forma de similitud, por lo que se convierte a distancia ($1 - \cos$) para garantizar propiedades métricas.

Usualmente usada en sistemas de recomendación de contenido. Cada ítem (artículo, película, producto) se representa como embedding; la similitud coseno identifica los k vecinos más cercanos en el espacio semántico. Usado en motores de búsqueda, plataformas de streaming y e-commerce (Amazon, Netflix, Spotify).

3.4 Distancia de Mahalanobis

$$d(x, y) = \sqrt{(x - y)^T \cdot S^{-1} \cdot (x - y)}$$

Generalización de la distancia euclidiana que incorpora la matriz de covarianza S de los datos, corrigiendo tanto la escala individual de cada variable como las correlaciones entre ellas. Cuando $S = I$ (identidad) se reduce a la euclidiana. **No requiere estandarización previa.** Su limitación principal es el costo computacional $O(d^2)$ para estimar S y la necesidad de que $n \gg d$ para una estimación estable. Con p variables, se recomienda $n > 5p$ observaciones mínimo.

La detección de anomalías multivariadas en manufactura (control de calidad) son casos de uso que comúnmente emplea distancia euclidiana. Un producto se describe por múltiples sensores correlacionados (temperatura, presión, vibración). La distancia de Mahalanobis al centroide de la clase normal detecta productos defectuosos que serían invisibles con distancia euclidiana por el efecto de correlación.

3.5 Índice / Distancia de Jaccard

$$J(A,B) = |A \cap B| / |A \cup B| \quad \text{dist}(A,B) = 1 - J(A,B)$$

Mide el solapamiento entre dos conjuntos. Para vectores binarios: J = número de posiciones donde ambos valen 1, dividido por el número de posiciones donde al menos uno vale 1. Insensible a las co-ocurrencias de ceros, lo que la hace ideal para datos dispersos (sparse). Se extiende a multiconjuntos (ponderada) y textos vía shingling + MinHash para estimación aproximada eficiente en corpus masivos.

La deduplicación y detección de plagio en textos es una aplicación frecuente de la distancia de Jaccard. Cada documento se convierte en un conjunto de n -gramas de caracteres; la similitud Jaccard identifica pares de documentos cuasi-duplicados. MinHash + Locality-Sensitive Hashing (LSH) reduce la complejidad a $O(n)$ en lugar de $O(n^2)$ para corpus de millones de documentos (Google, Wikipedia).

4. Guía Práctica de Selección

Situación	Métrica recomendada	Justificación
Datos numéricos continuos, baja dimensión	Euclidiana	Geometría intuitiva, k-means estándar
Datos con outliers o distribución pesada	Manhattan	Penalización lineal, no cuadrática
Datos de texto, embeddings	Coseno	Invarianza a longitud del documento
Variables con correlación y escala mixta	Mahalanobis	Corrige covarianza, no requiere escalado
Datos binarios o conjuntos dispersos	Jaccard	Diseñada para solapamiento de conjuntos
Alta dimensión ($d > 100$)	Coseno o Manhattan	Menor concentración de distancias
Series temporales con desfase	DTW	Permite alineamiento elástico temporal

5. Referencias Bibliográficas

- [1] Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer. [NYU DS-GA 1003 — Core textbook]
- [2] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2nd ed.). Springer. Recuperado de <https://hastie.su.domains/ElemStatLearn/>
- [3] Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press. [TU Berlin ML Group — recommended reading]
- [4] Deisenroth, M. P., Faisal, A. A., & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University

Press. Recuperado de <https://mml-book.github.io/>

[5] Beyer, K., Goldsmith, J., Ramakrishnan, R., & Shaft, U. (1999). When is 'nearest neighbor' meaningful? *Proceedings of ICDT*, 1999, 217–235. [Curse of dimensionality — distancias en alta dimensión]

[6] Jaccard, P. (1912). The distribution of flora in the alpine zone. *New Phytologist*, 11(2), 37–50.

[7] Mahalanobis, P. C. (1936). On the generalised distance in statistics. *Proceedings of the National Institute of Sciences of India*, 2(1), 49–55.

[8] Salton, G., & McGill, M. J. (1983). *Introduction to Modern Information Retrieval*. McGraw-Hill. [Similitud coseno en recuperación de información]

[9] Universität Münster — Institut für Informatik. (2023). *Lecture Notes: Data Mining and Machine Learning*. Disponible en el portal interno de la institución.

[10] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press. Recuperado de <https://www.deeplearningbook.org/>