



Bitácora de Desempeño

Tercer cuatrimestre

**Asignación III. Preparación de Columnas
para el Modelado de Datos**

Dr. **MARCOS YAMIR GOMEZ**

Jessica Melani Romero Lora

Matrícula 253220116

10 de mayo del 2026

Tabla de contenido

1. Introducción.....	3
2. Importación y carga de datos.....	4
2.1 Limpieza del separador decimal.....	4
3. Reestructuración long → wide con pivot_table.....	5
3.2. Creación de total_entertainment.....	6
4. Exportación.....	6
Conclusiones.....	8

1. Introducción

El presente pipeline representa la continuación de la documentación presentada en entregas anteriores, bajo la modificación del dataset `entertainment.csv`, donde cada fila representa una categoría de entretenimiento por estudiante. Mediante `pivot_table` se reestructura a formato wide obteniendo **una fila única por estudiante** con columnas `video_games`, `tv_shows`, `movies` y `books`. Los valores nulos resultantes del pivot se imputan con la media de cada columna para preservar la distribución del consumo.

De este procedimiento utilizando pivot se derivan dos variables nuevas sumamente útiles para la organización total de los datos, esto nos permitirá conocer la suma total de las cuatro columnas así como la cantidad de dispositivos utilizados para el consumo de entretenimiento entre los estudiantes. Por una parte:

- `total_entertainment`: suma horizontal de las cuatro columnas, representando el total de horas semanales consumidas por estudiante en todas las categorías.
- `pct_screen`: razón entre el consumo de pantallas (`video_games + tv_shows + movies`) y `total_entertainment`, expresando la proporción del entretenimiento digital sobre el total individual.

El dataset resultante se exporta como `entertainment_wide_img1.csv`.

2. Importación y carga de datos

Se carga el dataset desde un archivo CSV utilizando `pandas.read_csv`. El Data Frame resultante `df` se encuentra en formato *long*, donde cada registro corresponde a una combinación única de estudiante y categoría de entretenimiento, con su respectivo valor de horas semanales.

```
1 import pandas as pd
2 import numpy as np
3
4 # Importar datos
5 df = pd.read_csv("entertainment.csv")
6 print(f"[1] Shape original (long): {df.shape}")
7 print(df.head(4), "\n")
```

2.1 Limpieza del separador decimal

La columna `hours_per_week` puede contener valores con coma como separador decimal (convención europea/latinoamericana). Se convierte primero a cadena de texto con `astype(str)` para aplicar `str.replace(",", ".")`, normalizando el formato numérico. `str.strip()` elimina espacios residuales. Finalmente, `pd.to_numeric(..., errors="coerce")` convierte la columna a tipo numérico, transformando cualquier valor no parseable en `NaN`.

```
10 df["hours_per_week"] = (
11     df["hours_per_week"].astype(str).str.replace(",", ".").str.strip()
12 )
13 df["hours_per_week"] = pd.to_numeric(df["hours_per_week"], errors="coerce")
14
```

3. Reestructuración long → wide con pivot_table

La función `pivot_table` transforma el formato *long* a *wide*, asignando una fila única por estudiante (`index="name"`) y una columna por categoría de entretenimiento (`columns="entertainment"`), de esta manera la estructura de la base de datos cambia para un mejor manejo de la información. Por otra parte, el agregador `aggfunc="mean"` calcula el promedio en caso de registros duplicados. Finalmente, la función `reset_index()` convierte el índice en columna regular. Se elimina el nombre del eje de columnas con `columns.name = None` y se reordena explícitamente para garantizar consistencia estructural.

```
15 # Pivot long → wide
16 df_wide = df.pivot_table(
17     index="name",
18     columns="entertainment",
19     values="hours_per_week",
20     aggfunc="mean",
21 ).reset_index()
22 df_wide.columns.name = None
23 df_wide = df_wide[["name", "video_games", "tv_shows", "movies", "books"]]
```

3.1 Imputación de valores nulos con media de columna

El pivot genera `NaN` en celdas donde un estudiante no tiene registro para una categoría. Se itera sobre las cuatro columnas numéricas y se sustituyen los nulos con la media aritmética de cada columna redondeada a dos decimales. Esta estrategia de imputación preserva la distribución estadística del dataset sin introducir sesgo por cero.

3.2. Creación de `total_entertainment`

Se genera una nueva columna mediante suma horizontal de las cuatro columnas de consumo. Representa el total agregado de horas semanales dedicadas a entretenimiento por cada estudiante, independientemente de la categoría.

```
25 # Imputar nulos con media de columna
26 for col in ["video_games", "tv_shows", "movies", "books"]:
27     df_wide[col] = df_wide[col].fillna(round(df_wide[col].mean(), 2))
28
29 # total_entertainment: suma de todos los tipos por estudiante
30 df_wide["total_entertainment"] = (
31     df_wide["video_games"] + df_wide["tv_shows"] + df_wide["movies"] + df_wide["books"]
32 )
33
```

3.3 Creación de `pct_screen`

Se calcula la proporción del consumo de entretenimiento digital sobre el total individual. El numerador agrupa las tres categorías de pantalla (`video_games`, `tv_shows`, `movies`), mientras el denominador utiliza `total_entertainment` previamente calculado. El resultado, redondeado a tres decimales, expresa un valor entre 0 y 1 donde 1 indica consumo exclusivamente digital.

```
35 df_wide["pct_screen"] = (
36     (df_wide["video_games"] + df_wide["tv_shows"] + df_wide["movies"])
37     / df_wide["total_entertainment"]
38 ).round(3)
39
40 print(f"Shape final: {df_wide.shape}")
41 print(df_wide.head(5))
42 print(df_wide.describe().round(3))
43
```

4. Exportación

El DataFrame final se serializa a CSV con `to_csv()`. El parámetro `index=False` evita que el índice numérico interno de pandas se escriba como columna en el archivo de salida.

```
44 df_wide.to_csv("entertainment_wide_img1.csv", index=False)
45 print("\n✓ Guardado: entertainment_wide_img1.csv")
```

Conclusiones

El pipeline desarrollado demuestra que la reestructuración de datos desde formato *long* a *wide* mediante `pivot_table` constituye una transformación fundamental para habilitar el análisis comparativo por estudiante. La imputación por media de columna garantiza que ningún registro quede excluido del cálculo de variables derivadas, preservando la representatividad estadística del dataset completo.

La variable `total_entertainment` provee una métrica agregada de consumo individual que permite comparar la intensidad de entretenimiento entre estudiantes independientemente de sus preferencias por categoría. Por su parte, `pct_screen` introduce una dimensión cualitativa relevante: cuantifica la proporción del tiempo de entretenimiento destinada a medios digitales, lo que posibilita segmentar a la población estudiantil según su perfil de consumo analógico versus digital. Ambas variables enriquecen sustancialmente el dataset original y constituyen features directamente utilizables en etapas posteriores de modelado o análisis exploratorio.

Link al repositorio:

https://github.com/jessicaromero-ctrl/Unsupervised-Learning/blob/main/as_ignacion3.py