



Reporte Técnico

Técnicas de Clustering Aplicadas al Dataset de Cereales

Tercer cuatrimestre
Aprendizaje no Supervisado
Dr. MARCOS YAMIR GOMEZ

Jessica Melani Romero Lora
03 de julio de 2026

Introducción

La presente práctica documenta la aplicación comparativa de tres técnicas de agrupamiento no supervisado como K-Means, Clustering Jerárquico Aglomerativo y DBSCAN sobre el dataset de cereales cereal.csv, compuesto por 74 productos y 5 variables numéricas: Calorías, Proteína, Grasa, Azúcares y Vitaminas. El objetivo aplicado es apoyar a Maven Supermarket en la organización de sus expositores de cereales por perfil nutricional y segmento de mercado.

El pipeline completo contempla cuatro fases: (1) preprocesamiento y transformación de datos, (2) agrupamiento con K-Means y selección de K óptimo mediante el método del codo, (3) análisis jerárquico mediante dendrogramas y clustermap, y (4) exploración de densidad con DBSCAN y grid search de hiperparámetros.

2. Descripción del Dataset

El dataset contiene 74 marcas de cereal con los siguientes atributos:

Variable	Tipo	Rango observado	Rol en el clustering
Calories	Numérico	50 – 160 kcal	Diferenciador primario
Protein (g)	Numérico	1 – 6 g	Indicador nutricional
Fat	Numérico	0 – 5 g	Excluido en fase jerárquica
Sugars	Numérico	-1 – 15 g	Discriminante clave
Vitamins and Minerals	Numérico	0 – 100 %DV	Discriminante clave

Tabla 1. Información de la base de datos central, características principales y tipo de datos.

Como podemos observar, el campo Sugars presenta un valor atípico de -1 en Quaker Oatmeal, indicativo de dato faltante codificado. Las variables Vitaminas y Calorías presentan la mayor varianza y dominan la distancia Euclidiana en los datos sin estandarizar, lo que justifica el proceso de escalado previo al clustering.

3. Fase 1 Aplicación de K-Means Clustering

3.1 Preprocesamiento

Se eliminaron las columnas categóricas Cereal Name y Manufacturer. Los 5 campos numéricos restantes se escalan con StandardScaler para normalizar la influencia de variables con distintas magnitudes. La imputación de nulos se realiza por media de columna, preservando la distribución estadística del dataset.

```
from sklearn.preprocessing import StandardScaler
from sklearn.cluster import KMeans

X = df.drop(columns=['Cereal Name', 'Manufacturer'])
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)

km2 = KMeans(n_clusters=2, random_state=42, n_init=10)
km2.fit(X_scaled)
df['cluster_2'] = km2.labels_
es[1], acc.concat([res[0]]) : acc
}
return go(f, seed, [])
}
```

3.2 K=2 — Resultados e Interpretación

El modelo con 2 clusters genera una partición equilibrada (38 vs 36 cereales) con centros bien diferenciados:

Cluster	Calorías	Proteína (g)	Grasa	Azúcares	Vitaminas	Perfil
0	116.3	2.1	1.4	10.3	32.2	Infantil / alto azúcar
1	94.2	2.9	0.5	3.1	24.3	Saludable / bajo azúcar

Tabla 2. Resultados obtenidos mediante partición de clusters para consumo infantil y adultos con restricciones alimentarias.

En esta tabla podemos ver cómo el Cluster 0 agrupa cereales con perfil de consumo infantil (Froot Loops, Cocoa Puffs, Corn Pops), mientras el Cluster 1 concentra productos orientados a adultos con restricciones alimentarias (All-Bran, Shredded Wheat, Special K). La variable Azúcares es el principal discriminante

entre

ambos

grupos.




Figura 1. Mapa de calor obtenido que muestra la característica nutricional y su agrupación en clúster correspondiente a partir del valor promedio.

3.3 Método del Codo — Selección de K óptimo

Se ajustaron 14 modelos K-Means para $K \in [2, 15]$ evaluando la inercia (suma de distancias cuadráticas intra-cluster). La segunda derivada de la curva identifica el codo en $K=4$, punto donde la reducción de inercia deja de ser proporcional al incremento en complejidad.

```
inertias = []
for k in range(2, 16):
    km = KMeans(n_clusters=k, random_state=42, n_init=10)
    km.fit(X_scaled)
    inertias.append(km.inertia_)

# Inercias clave:
# K=2: 265.94 | K=4: 163.44 | K=6: 110.94 | K=15: 46.14
```

Con $K=4$, los segmentos para Maven Supermarket son: (0) naturales/sin azúcar, (1) infantiles/azucarados, (2) ultra-fortificados en vitaminas y (3) calóricos con grasa moderada. El heatmap de centroides confirma que Vitaminas y Azúcares son las variables con mayor poder discriminativo entre segmentos.




Figura 2. Aplicación del método del codo para seleccionar el mejor número de clústers con resultado obtenido de K=4.

4. Fase 2 — Clustering Jerárquico Aglomerativo

4.1 Dendrograma — Datos Originales (5 variables)

Se aplica linkage de Ward sobre los datos sin estandarizar. La distancia euclidiana sin escalar favorece las variables de mayor magnitud (Calorías, Vitaminas), comprimiendo la separación entre grupos y haciendo visualmente identificables 3 clusters al aplicar un umbral de corte en distancia 150.

```
from scipy.cluster.hierarchy import dendrogram, linkage

linked_orig = linkage(X_orig, method='ward')
dendrogram(linked_orig, labels=labels, color_threshold=150)
ax.axhline(y=150, color='red', linestyle='--') # 3 clusters visibles
```




Figura 3. Dendrograma con los datos originales sin estandarización ni tratamiento de normalización previo.

Observación crítica: sin estandarizar, la variable **Vitaminas** (rango 0–100) domina el cálculo de distancias, lo que sesga la formación de clusters hacia diferencias en vitaminas más que en el perfil nutricional integral. Esto ilustra la importancia del preprocesamiento previo al clustering jerárquico.

4.2 Dendrograma: Datos Estandarizados (4 variables, sin Grasa)

Al estandarizar y excluir **Grasa** como variable con baja varianza relativa y menor relevancia nutricional para la segmentación de mercado, el dendrograma muestra ramas mucho más equilibradas. El umbral visual en distancia estandarizada 4.5 revela 4 clusters con mayor cohesión interna. Esto es importante para las siguientes fases.

```

scaler = StandardScaler()
X_std = scaler.fit_transform(
    df[['Calories', 'Protein (g)', 'Sugars', 'Vitamins and Minerals']]
)
linked_std = linkage(X_std, method='ward')
dendrogram(linked_std, labels=labels, color_threshold=4.5)
ax.axhline(y=4.5, color='red', linestyle='--') # 4 clusters visibles

```




Figura 4. Dendrograma con datos estandarizados donde el umbral de corte = 4 clústers.

4.3 Modelo Jerárquico K=4 + Clustermap

Se ajusta AgglomerativeClustering con K=4 sobre los datos estandarizados. El clustermap de seaborn combina el heatmap de valores con dendrogramas de filas y columnas, revelando la estructura **bidimensional** de la segmentación.

```
from sklearn.cluster import AgglomerativeClustering
import seaborn as sns

model = AgglomerativeClustering(n_clusters=4, linkage='ward')
labels_hier = model.fit_predict(X_std)

sns.clustermap(X_std_df, row_colors=row_colors,
               cmap='vlag', figsize=(10, 14))
```




Figura 5. Mapa de clústers por variable nutricional y nombre de producto agrupados de acuerdo a su clúster correspondiente.

Cluster	Calorías	Azúcares	Vitaminas	n	Perfil
1	76.3	1.75	15.6	8	Naturales / sin azúcar
2	117.5	11.6	24.0	24	Infantiles / alto azúcar
3	116.7	6.3	100.0	6	Ultra-fortificados
4	102.2	4.75	22.2	36	Estándar equilibrado

Tabla 3. Resultados obtenidos a partir de los clústers seleccionados (4)

5. Fase 3 — DBSCAN (Density-Based Spatial Clustering)

5.1 Fundamento y Parámetros

DBSCAN define clusters como regiones de alta densidad separadas por zonas de baja densidad. Sus hiperparámetros críticos son `eps` (radio de vecindad) y `min_samples` (mínimo de puntos para ser núcleo). A diferencia de K-Means, no requiere especificar `K` a priori y detecta outliers explícitamente como ruido (etiqueta -1).

5.2 Grid Search de Hiperparámetros

Se evaluaron 180 combinaciones de hiperparámetros ($\text{eps} \in [0.1, 2.0] \times \text{min_samples} \in [2, 10]$) sobre ambos datasets. Se aplicó un criterio de filtrado adicional: ruido máximo del 50% del dataset, descartando configuraciones con silhouette artificialmente alto pero, con la mayoría de puntos etiquetados como ruido.

```
from sklearn.cluster import DBSCAN
from sklearn.metrics import silhouette_score
import numpy as np

eps_values = np.round(np.arange(0.1, 2.1, 0.1), 1)
for eps in eps_values:
    for ms in range(2, 11):
        db = DBSCAN(eps=eps, min_samples=ms)
        labels = db.fit_predict(X_std)
        n_clusters = len(set(labels)) - (1 if -1 in labels else 0)
        n_noise = (labels == -1).sum()
        if n_clusters >= 2 and (n_noise/len(X_std)) <= 0.50:
            sil = silhouette_score(X_std[labels!=-1], labels[labels!=-1])
```

El heatmap de silhouette scores visualiza el espacio de búsqueda, mostrando que los valores más altos se concentran en eps bajo (0.3–0.4) con min_samples=2 para los datos estandarizados.

5.3 Resultados — Modelos Óptimos

Dataset	eps óptimo	min_samples	Silhouette	Clusters	Ruido (n)	Ruido (%)
Original	1.0	2	0.7621	13	34	46%
Estandarizado	0.3	2	0.8186	15	33	45%

Tabla 4. Comparación de métricas entre K-Means y DBSCAN.

Observación: DBSCAN identifica micro-clusters semánticamente coherentes que K-Means promedia. El alto porcentaje de ruido ($\approx 45\%$) es característico de este dataset con perfiles nutricionales muy dispersos y refleja que muchos cereales son genuinamente únicos en su combinación de atributos, comportándose como outliers desde la perspectiva de densidad.

5.4 Interpretación de Micro-clusters (Modelo Estandarizado)

Cluster	n	Cereales representativos	Perfil nutricional
6	7	Cocoa Puffs, Corn Pops, Trix, Frosted Flakes	Alto azúcar — infantiles
7	5	Corn Chex, Crispix, Kix, Rice Krispies	Bajo azúcar — livianos
2	4	Apple Jacks, Froot Loops, Lucky Charms	Azucarados coloridos
0	2	100% Bran, All-Bran	Alta fibra — salud digestiva
12	2	Product 19, Total Whole Grain	Ultra-fortificados
RUIDO	33	Cheerios, Special K, Grape-Nuts...	Perfiles mixtos atípicos

Tabla 5. Comparación de micro clústers a partir del modelo estandarizado y tipo de cereal correspondiente.

6. Análisis Comparativo de Técnicas

Criterio	K-Means (K=4)	Jerárquico (K=4)	DBSCAN
K requerido	Sí (método del codo)	Sí (dendrograma)	No
Forma de clusters	Esférica	Flexible	Arbitraria
Outliers	Asignados al cluster más cercano	Asignados	Etiquetados explícitamente (-1)
Granularidad	4 segmentos amplios	4 segmentos con jerarquía	15 micro-clusters
Silhouette	No calculado	No calculado	0.8186
Aplicabilidad Maven	Alta: segmentos de exhibición	Alta: jerarquía de producto	Media: demasiados grupos
Sensibilidad a escala	Alta	Alta	Alta

Tabla 6. Comparación de técnicas por modelo desplegado, identificación de atributos y mejores características para la toma de decisiones en el mercado..

Para la implementación práctica en Maven Supermarket se recomienda K-Means con $K=4$ como modelo primario de segmentación de expositores, complementado con el análisis del modelo DBSCAN para identificar cereales outlier que merecen posicionamiento individual (nichos especializados como ultra-fortificados o sin azúcar extremo). Esto con el objetivo de abarcar los distintos nichos de mercado y de consumo del supermercado.

7. Conclusiones

A partir del despliegue de los modelos, K-Means con $K=4$ constituye la solución más interpretable y operacionalmente viable para Maven Supermarket. Los cuatro segmentos — naturales, infantiles, ultra-fortificados y estándar — corresponden

directamente a categorías de expositor reconocibles por el consumidor final. El clustering jerárquico aporta una perspectiva complementaria valiosa: el dendrograma sobre datos estandarizados (sin Grasa) revela la misma estructura de 4 grupos con mayor claridad visual, validando la técnica partición de K-Means desde un enfoque independiente.

Por otra parte, DBSCAN demuestra que el dataset contiene una proporción significativa de cereales con perfiles nutricionales únicos ($\approx 45\%$ clasificados como ruido), lo que sugiere que una segmentación rígida en K clusters puede subestimar la diversidad real del catálogo. Esta opción no es la más conveniente, porque abre la posibilidad de dejar fuera a un sector de consumidores subrepresentados, algo que K-Means logra captar de manera directa.

El estandarizado previo al clustering es determinante, se observó que sin normalizar, **la variable Vitaminas domina la distancia Euclidiana y sesga los clusters hacia diferencias en contenido vitamínico**, ignorando patrones en Calorías y Azúcares igualmente relevantes para la segmentación de mercado, específicamente para aquellos sectores de consumo que no dominan la muestra seleccionada como podría ser clientes con restricciones alimentarias de azúcares y ultraprocesados.

Finalmente, Azúcares y Vitaminas son las variables con mayor poder discriminativo en todos los modelos aplicados, confirmando su relevancia como ejes principales de diferenciación nutricional en el portafolio de cereales analizado. En un futuro, las técnicas aplicadas permitirán identificar variables complementarias para los nichos de mercado prioritarios o con menor gasto en cereales, atender a estos segmentos permitirá incrementar los ingresos de distintos productos así como adecuarlos a las nuevas necesidades y exigencias nutricionales de los consumidores.