



Informe de resultados

Tercer cuatrimestre

Aprendizaje no Supervisado Dr.

Marcos Yamir Gomez

Jessica Melani Romero Lora

Victor Manuel Santos Martínez

10 de mayo del 2026



**Plantilla de informe
Tercer cuatrimestre
Aprendizaje No Supervisado**

Tabla de contenido

1. Introducción.....	3
2. Fundamento técnico.....	3
3. Metodología.....	4
4. Resultados.....	7
6. Potencial metodológico.....	10



1. Introducción

La segmentación de clientes es una de las aplicaciones más consolidadas del aprendizaje automático no supervisado en contextos comerciales. A diferencia de la clasificación, el agrupamiento no requiere de etiquetado previo, las agrupaciones emergen desde la estructura y el desarrollo interno de los datos,

esto permite descubrir patrones latentes de comportamiento que no son evidentes mediante análisis descriptivo.

En esta tarea se desarrolló un pipeline de segmentación de clientes de una tienda en línea, se realizó una segmentación en clusters a partir de sus patrones de comportamiento y observaciones sobre su pertenencia a grupos determinados. Durante el proceso, se identificaron aplicaciones prácticas para la toma de decisiones empresariales. Los principales criterios de agrupamiento fueron:

Criterio	Variable principal	Métricas
Tiempo de uso en la app	Tiempo en App (hrs/semana)	Promedio de horas, edad y compras por grupo
Edad generacional	Edad	Rangos etarios predominantes
Volumen de compras	Compras Mensuales	Promedio de compras mensuales

2. Fundamento técnico

El presente proyecto aplica el algoritmo K-Means a una base de datos de e-commerce sintética con el objetivo de identificar tres variables operacionales basadas en el comportamiento de compras de los clientes: interacción con la app (engagement temporal), intensidad transaccional (compras mensuales) y posicionamiento demográfico (edad). Estas variables se estandarizaron con la función Standard Scaler, particionando 50 registros en $k = 3$ grupos determinados mediante el método de codo y el coeficiente de Silhouette.

A partir de esta segmentación, se generaron tres tipologías de clientes: los Exploradores Digitales, Compradores Generacionales y los Compradores Intensivos, los cuales exhiben perfiles de comportamiento y estadísticos diferentes. Los resultados se interpretan en términos de perfiles de usuario y se traducen en recomendaciones operativas concretas para la toma de decisiones empresariales.

Los objetivos de este proyecto son aplicar K-Means sobre variables comportamentales y demográficas estandarizadas, de igual manera se busca determinar el número óptimo de clusters mediante el método del codo y el coeficiente de Silhouette. Los objetivos complementarios son caracterizar cada



segmento estadísticamente para asignarle una denominación. Así como derivar recomendaciones estratégicas de negocio para cada segmento.

3. Metodología

El análisis implementó un pipeline de cuatro etapas que incluye un análisis exploratorio de datos (EDA), preprocesamiento, optimización del número de clusters y aplicación del modelo. La implementación se realizó en Python mediante el uso de bibliotecas como scikit learn, pandas, matplotlib y seaborn. Durante la etapa de análisis exploratorio se examinaron las distribuciones univariadas de las tres variables numéricas mediante histogramas con indicadores de media.

1. Carga de librerías y datos

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.cluster import KMeans
from sklearn.metrics import silhouette_score

sns.set_theme(style="whitegrid", palette="muted")
plt.rcParams["figure.figsize"] = (10, 5)
plt.rcParams["figure.dpi"] = 120 🐼

# Cargar datos
df = pd.read_csv("Actividad 1 - Hoja 1.csv")
df.head(10)
```

Python

	Cliente	Edad	Compras Mensuales	Tiempo en App (hrs/semana)	Categoría de productos comprados	Método de pago
0	C01	18	2	8	Electrónica	Tarjeta
1	C02	19	1	7	Videojuegos	Tarjeta
2	C03	20	3	9	Electrónica	PayPal
3	C04	21	2	6	Accesorios	Tarjeta
4	C05	22	4	8	Videojuegos	PayPal
5	C06	24	5	5	Ropa	Transferencia
6	C07	25	6	4	Ropa	Tarjeta
7	C08	26	7	4	Hogar	Transferencia
8	C09	27	8	3	Hogar	Tarjeta
9	C10	28	6	5	Ropa	Efectivo

Se calculó una matriz de correlación de Pearson para detectar multicolinealidad, sin embargo, no se encontraron valores nulos en ninguna columna del conjunto



de datos. Las distribuciones de edad y compras mensuales son aproximadamente uniformes; El tiempo del usuario en app presenta una leve asimetría positiva.

En la etapa de preprocesamiento, se aplicó estandarización mediante StandardScaler (promedio de cero, varianza unitaria) a las tres variables de

entrada. Este paso es obligatorio en algoritmos basados en distancias para evitar que variables con mayor magnitud dominen la función objetivo. Es importante mencionar que, las variables categóricas fueron excluidas de la matriz de entrada al modelo.

2. Analisis exploratorio de los datos (EDA)

```
# Información general del dataset
print("Dimensiones:", df.shape)
print("\nTipos de datos:")
print(df.dtypes)
print("\nEstadísticas descriptivas:")
df.describe()
```

Python

```
''' Dimensiones: (30, 6)

Tipos de datos:
Cliente                object
Edad                   int64
Compras Mensuales      int64
Tiempo en App (hrs/semana)  int64
Categoría de productos comprados  object
Método de pago         object
dtype: object

Estadísticas descriptivas:
'''
```

	Edad	Compras Mensuales	Tiempo en App (hrs/semana)
count	30.000000	30.000000	30.000000
mean	35.100000	9.100000	4.033333
std	10.691118	6.115836	2.785224
min	18.000000	1.000000	1.000000
25%	26.250000	3.250000	2.000000
50%	35.000000	8.500000	3.000000
75%	43.750000	14.000000	6.750000
max	54.000000	20.000000	9.000000

Por otra parte, para la selección de k , se evaluaron dos criterios complementarios en donde $k \in \{2, \dots, 8\}$: (i): el Método del Codo, el cual determina el punto de inflexión en la curva de inercia intra-cluster; y de manera complementaria, el coeficiente de Silhouette que mide la separación relativa entre clusters. (rango: -1 a +1, donde valores cercanos a 1 indican una separación óptima). Ambos criterios



convergió en $k = 3$, valor que además coincide con el número de variables definidos a priori.

Tipos de datos:

Cliente	object
Edad	int64
Compras Mensuales	int64
Tiempo en App (hrs/semana)	int64
Categoría de productos comprados	object
Método de pago	object
dtype:	object

Estadísticas descriptivas:

	Edad	Compras Mensuales	Tiempo en App (hrs/semana)
count	30.000000	30.000000	30.000000
mean	35.100000	9.100000	4.033333
std	10.691118	6.115836	2.785224
min	18.000000	1.000000	1.000000
25%	26.250000	3.250000	2.000000
50%	35.000000	8.500000	3.000000
75%	43.750000	14.000000	6.750000
max	54.000000	20.000000	9.000000

```
# Verificar valores nulos
print("Valores nulos por columna:")
print(df.isnull().sum())
print(f"\nTotal de registros: {len(df)}")
print(f"Categorías de productos: {df['Categoría de productos comprados'].unique()}")
print(f"Metodos de pago: {df['Método de pago'].unique()}")
```

```
Valores nulos por columna:
Cliente          0
Edad             0
Compras Mensuales 0
Tiempo en App (hrs/semana) 0
Categoría de productos comprados 0
Método de pago   0
dtype: int64

Total de registros: 30
Categorías de productos: ['Electrónica' 'Videojuegos' 'Accesorios' 'Ropa' 'Hogar'
 'Electrodomésticos' 'Deportes' 'Viajes']
Metodos de pago: ['Tarjeta' 'PayPal' 'Transferencia' 'Efectivo']
```

Durante la aplicación del modelo pudimos observar que K-Means logró un ajuste sobre la matriz estandarizada con $k = 3$, random state = 42 y n_init = 10 para garantizar reproducibilidad y estabilidad del modelo. Las asignaciones de cluster se proyectaron sobre el dataset original para el análisis interpretativo. Mientras que para la caracterización post-hoc empleo medias agrupadas y valores modales de las variables categóricas.



4. Resultados

Como podemos observar en la siguiente tabla, los valores promedio de las variables de agrupamiento y los atributos categóricos más frecuentes para cada segmento identificado arrojan relaciones inversas, así como posiciones intermedias entre grupos de compradores.


Exploradores Digitales	~20	Baja	Alta	Electrónica / Videojuegos	Tarjeta / PayPal
Compradores Generacionales	~30	Moderada	Moderado	Ropa / Hogar	Tarjeta / Transferencia
Compradores Intensivos	~45	Alta	Baja	Hogar / Electrodomésticos	Transferencia / Tarjeta

Tabla 1. Estadísticas descriptivas por cluster (promedios de variables de agrupamiento)

Se identificó una relación inversa estadísticamente coherente entre el tiempo de uso de la aplicación y el volumen de compras: en donde los clientes más jóvenes (Exploradores Digitales) presentan una alta navegación pero baja conversión a clientes de la aplicación. Mientras que los clientes de mayor edad (Compradores Intensivos) realizan más compras en un menor tiempo de permanencia en la app. Por su parte, los Compradores Generacionales ocupan una posición intermedia en ambas dimensiones.



Este patrón sugiere que la aplicación cumple funciones distintas según el grupo etario: es tanto un medio de exploración y de descubrimiento para usuarios jóvenes, como herramienta transaccional orientada a objetivos específicos para compradores maduros.



evaluado, confirmando la calidad de la separación entre clusters y respaldando la elección de tres segmentos como partición óptima del conjunto de datos.



5. Conclusiones

Se identificó una relación inversa estadísticamente coherente entre el tiempo de uso de la aplicación y el volumen de compras: los clientes más jóvenes (Exploradores Digitales) presentan alta navegación pero baja conversión, mientras que los clientes de mayor edad (Compradores Intensivos) realizan más compras en menor tiempo de sesión. Los Compradores Generacionales ocupan una posición intermedia en ambas dimensiones.

Este patrón sugiere que la aplicación cumple funciones distintas según el grupo etario: medio de exploración y descubrimiento para usuarios jóvenes, y herramienta transaccional orientada a objetivos para compradores maduros. El coeficiente de Silhouette alcanzó su valor máximo en $k = 3$ dentro del rango evaluado, confirmando la calidad de la separación entre clusters y respaldando la elección de tres segmentos como partición óptima del conjunto de datos.

Los tres clusters se alinean con arquetipos comportamentales reconocibles en la literatura de comportamiento del consumidor. El grupo uno, de Exploradores Digitales corresponden a un perfil caracterizado por búsqueda de información característica de cohortes jóvenes nativos digitales, con alta sensibilidad a estímulos visuales y bajo compromiso de compra inmediata.

El segundo grupo de Compradores Generacionales reflejan patrones de compra moderados distribuidos en múltiples categorías, consistentes con las prioridades de gasto en la etapa adulta intermedia. Por otra parte, los Compradores Intensivos



exhiben comportamientos de compra dirigidas a objetivos, con alta frecuencia y

preferencia por categorías de hogar y electrodomésticos, compatible con modelos de lealtad establecida.

La segmentación obtenida nos brinda estrategias de negocio relevantes para aumentar el volumen de compra de los consumidores identificados, en la siguiente tabla se agrupan propuestas a partir de las dinámicas identificadas:

Exploradores Digitales	Notificaciones push con ofertas flash en electrónica y videojuegos; gamificación del flujo de compra; descuentos de primera compra; retargeting personalizado a sus intereses personales (maquillaje, accesorios, zapatos, ropa).
Compradores Generacionales	Programas de puntos y lealtad; ofertas cruzadas entre categorías (ropa + hogar); facilitar pagos recurrentes; campañas de correo personalizadas.
Compradores Intensivos	Membresía VIP con envío prioritario; suscripciones de reabastecimiento automático; descuentos por volumen en hogar y electrodomésticos; canal de atención dedicado.

Tabla 2. Recomendaciones estratégicas por segmento de clientes

Algunas limitaciones importantes identificadas son principalmente el conjunto de datos, el cual es sintético y de tamaño reducido ($n = 50$), no obstante, estos resultados no son representativos o generalizables por lo que deben de validarse a priori el deployment del modelo en sistemas de producción. Por otra parte, K-Means asume clusters esféricos de tamaño similar y es sensible a valores atípicos, en este sentido, se sugiere evaluar alternativas como DBSCAN o modelos de mezclas gaussianas sobre datos reales. Es importante mencionar que, el análisis efectuado es de corte transversal, por lo que no es capaz de capturar dinámicas temporales del comportamiento del cliente; las variables categóricas como categoría de producto y método de pago se emplearon únicamente en la fase interpretativa, no como insumo del modelo de agrupamiento.

6. Potencial metodológico

El presente reporte demostró que K-Means, aplicado sobre variables comportamentales y demográficas estandarizadas, produce segmentos de clientes internamente coherentes, estadísticamente separables y operativamente interpretables a partir de datos de comercio electrónico. Los tres segmentos identificados —Exploradores Digitales, Compradores Generacionales y Compradores Intensivos— se corresponden con arquetipos del comportamiento



del consumidor y ofrecen una base sólida para estrategias de personalización diferenciada.

El hallazgo central —la relación inversa entre tiempo de navegación y volumen de compras— tiene implicaciones directas para la optimización de conversión: reducir la fricción en el proceso de compra para usuarios exploradores y agilizar la experiencia transaccional para compradores orientados a objetivos constituyen las intervenciones de mayor impacto potencial.

Como trabajo futuro se propone: (i) aplicar el mismo pipeline sobre datos longitudinales de transacciones reales; (ii) incorporar indicadores RFM (Recencia, Frecuencia, Valor Monetario) al espacio de características; y (iii) comparar el rendimiento de K-Means frente a métodos de agrupamiento basados en densidad y modelos probabilísticos.