



Encuesta Trimestral de Satisfacción Turística: Reporte de Resultados Cuantitativo

**Tercer cuatrimestre
Aprendizaje no Supervisado
Dr. MARCOS YAMIR GOMEZ**

**JESSICA MELANI ROMERO LORA (253220116)
12 de julio de 2026**

Introducción

La encuesta trimestral aplicada a turistas que visitan la ciudad recopila la valoración promedio que cada visitante otorga a cuatro categorías de experiencia: museos, parques, restaurantes y locales de ocio nocturno. Estas valoraciones alimentan indicadores de calidad turística utilizados para orientar decisiones de promoción, inversión en infraestructura cultural y recreativa, y estrategias de atracción de visitantes.

Sin embargo, en cada levantamiento se identifican patrones de respuesta que se apartan sustancialmente del comportamiento mayoritario de la muestra. Estos casos —ya sea por errores de captura, extremos genuinos de experiencia o perfiles de consumo turístico atípicos— distorsionan las medidas de tendencia central y pueden sesgar las conclusiones derivadas del estudio.

El objetivo de este reporte es identificar de manera sistemática y reproducible a los turistas cuyas valoraciones constituyen anomalías estadísticas dentro del conjunto de datos, empleando el algoritmo Isolation Forest, una técnica de aprendizaje no supervisado especializada en detección de outliers en espacios multivariados. Se documenta el proceso de exploración de datos, la aplicación del modelo bajo dos niveles de sensibilidad (contaminación de 0.01 y 0.005), y el análisis comparativo de los resultados obtenidos.

Alcance del Análisis

- Fuente de datos: tripadvisor_reviews.csv, con 980 registros de turistas.
- Variables analizadas: avg_museum_rating, avg_park_rating, avg_restaurant_rating, avg_nightlife_rating (escala continua, rango observado 1.0–4.6).
- La columna identificadora user_id fue excluida del modelo por no aportar información de comportamiento.
- Técnica aplicada: Isolation Forest, con dos configuraciones de contaminación (1.0% y 0.5%) para evaluar sensibilidad del umbral de detección.

2. Desarrollo de la Práctica

2.1 Análisis Exploratorio: Gráfico de Pares

Como paso previo a la modelación, se generó un gráfico de pares (pairplot) de Seaborn para visualizar la distribución univariada de cada variable en la diagonal y

las relaciones bivariadas entre categorías fuera de ella. Este análisis exploratorio permite formarse una hipótesis inicial sobre dónde podrían concentrarse los valores atípicos antes de aplicar el modelo. Posteriormente se presenta el espacio de valoraciones y puntuaciones de anomalías identificadas durante la ejecución.




Figura 1. Pairplot base de las cuatro categorías de valoración (n = 980).

Figura 1. Espacio de valoraciones y puntuación de anomalía
(Isolation Forest, contaminación = 0.01)




Figura 1. Espacio de valoraciones y puntuación de anomalías.

Descripción del conjunto de datos

El archivo analizado contiene 980 observaciones y cuatro variables numéricas continuas, cada una correspondiente a la valoración promedio otorgada por un turista a una categoría de experiencia. La tabla 1 resume el rango y la dispersión observados en cada variable.

Nivel de contaminación	Anomalías detectadas	% del total	Observaciones clave
avg_museum_rating	1.34 – 4.22	$\mu = 1.89$	$\sigma = 0.33$

avg_park_rating	1.00 – 4.64	$\mu = 2.35$	$\sigma = 0.48$
avg_restaurant_rating	1.13 – 4.62	$\mu = 2.01$	$\sigma = 0.79$
avg_nightlife_rating	1.15 – 4.44	$\mu = 1.53$	$\sigma = 0.28$

Tabla 1. Rango, media (μ) y desviación estándar (σ) por categoría de valoración.

Metodología Isolation Forest

Isolation Forest construye un ensamble de árboles de aislamiento que particionan aleatoriamente el espacio de variables. Los puntos anómalos, al ser diferentes del grueso de las observaciones, requieren en promedio menos particiones para quedar aislados en una hoja, lo que se traduce en una longitud de camino (path length) más corta y, por tanto, en una puntuación de anomalía más alta. A diferencia de métodos basados en distancia o densidad, esta técnica escala bien a múltiples dimensiones y no exige supuestos de distribución normal.

El parámetro de contaminación (contamination) define la proporción esperada de observaciones anómalas en el conjunto de datos y determina el umbral de corte sobre la puntuación de anomalía. Se evaluaron dos configuraciones sobre las cuatro variables de valoración (museum, park, restaurant, nightlife), sin normalización previa dado que todas están en la misma escala (1–5), con semilla aleatoria fija para garantizar reproducibilidad.

Resultados: contaminación = 0.01

Con un nivel de contaminación de 0.01, el modelo identificó 10 turistas anómalos, equivalentes al 1.02% de la muestra total. La figura 2 muestra su ubicación dentro del gráfico de pares, coloreados en rojo frente al resto de la muestra en morado.





Figura 2. Anomalías detectadas (rojo) con contaminación = 0.01 — 10 casos.

El patrón dominante entre las anomalías es una valoración de ocio nocturno considerablemente más alta que la del resto de la muestra (aproximadamente 2.4–4.4, frente a una media general de 1.53), frecuentemente acompañada de valoraciones bajas o dispersas en museos y parques. Esto sugiere un perfil de turista orientado al consumo nocturno, claramente diferenciado del patrón mayoritario de visitante cultural. A continuación, se presenta un gráfico de superficie 3D que muestra el paisaje que el ensamble fue capaz de construir. en este gráfico se incluyen, variables diversas como restaurantes, ocio nocturno, entre otras, valoradas ampliamente durante la encuesta.

Figura 2. Superficie de la función de anomalía aprendida
(otras variables fijas en su mediana)



Resultados: contaminación = 0.005

Al reducir el nivel de contaminación a 0.005, el modelo se vuelve más estricto y retiene únicamente 5 observaciones como anómalas (0.51% de la muestra), correspondientes a los casos con las puntuaciones de anomalía más extremas.





Figura 3. Anomalías detectadas (rojo) con contaminación = 0.005 — 5 casos.

Los cinco casos que se retiran al bajar el umbral (índices 274, 422, 592, 677 y 903) corresponden a turistas con perfiles moderadamente atípicos —cercanos a la frontera de decisión— mientras que el núcleo de 5 observaciones que persiste en ambas configuraciones representa los casos con mayor separación multivariada respecto al resto de la muestra. A continuación, se presenta un diagrama conceptual del mecanismo de aislamiento comparando el número de particiones aleatorias necesarias para identificar una anomalía entre un punto normal y un punto anómalo.

Figura 3. Mecanismo de aislamiento del Isolation Forest:
los puntos anómalos requieren menos particiones aleatorias para quedar aislados



Análisis Comparativo


Nivel de contaminación	Anomalías detectadas	% del total	Observaciones clave
0.01 (1.0%)	10	1.02%	Incluye casos extremos y moderados
0.005 (0.5%)	5	0.51%	Solo los casos más extremos

Tabla 2. Comparación de resultados entre niveles de contaminación.

La reducción del parámetro de contaminación a la mitad no redujo proporcionalmente el número de anomalías detectadas de forma lineal simple, sino que el modelo conservó exactamente el subconjunto de observaciones con mayor separación estadística, descartando los casos borderline. Esto confirma que los 5 turistas retenidos en ambas configuraciones constituyen el grupo de anomalías más robusto y menos sensible a la elección del umbral.

En este gráfico podemos observar un ranking de los 15 turistas con mayor puntuación de anomalía según Isolation Forest.

Figura 4. Ranking de los 15 turistas con mayor puntuación de anomalía según Isolation Forest



Para complementar, el análisis se implementó una proyección de análisis de componentes principales, a través de la cual se identificaron los elementos anómalos del resultado, en esta ocasión se realizaron dos análisis el primero se efectuó con dos componentes (27.5%) y el segundo con 30.1%. Con dos componentes el análisis detectó un mayor número de elementos anómalos, mientras que con un componente el rango de detección disminuye a 3 elementos anómalos.

Conclusiones

El análisis mediante Isolation Forest permitió identificar de forma sistemática y reproducible a los turistas cuyas valoraciones distorsionan los resultados agregados de la encuesta trimestral. Las principales conclusiones son las siguientes: La variable con mayor poder discriminante para detectar anomalías es avg_nightlife_rating: los turistas atípicos valoran el ocio nocturno muy por encima del comportamiento mayoritario de la muestra. El perfil anómalo típico

corresponde a un visitante con un patrón de consumo turístico distinto al dominante (más orientado a vida nocturna que a museos o parques), y no necesariamente a errores de captura de datos. Con contaminación 0.01 se detectan 10 casos (1.02%); con 0.005 se detectan 5 casos (0.51%), correspondientes a los outliers más extremos y estadísticamente más robustos.

Los 5 casos que se mantienen en ambos niveles de contaminación son los candidatos prioritarios para excluir o marcar en los reportes agregados de satisfacción turística, dado que su separación del resto de la muestra es consistente independientemente del umbral elegido.

Se recomienda, de cara a próximos levantamientos, aplicar este mismo procedimiento de forma rutinaria antes de calcular los indicadores agregados de satisfacción, utilizando un nivel de contaminación de 0.005 cuando se busque conservar únicamente los outliers más inequívocos, y de 0.01 cuando se prefiera una revisión más amplia que incluya casos moderadamente atípicos. Asimismo, se sugiere dar seguimiento cualitativo a los turistas identificados como anómalos, con el fin de determinar si su patrón responde a un segmento de mercado desatendido (turismo nocturno) o a inconsistencias en el proceso de captura de la encuesta.